

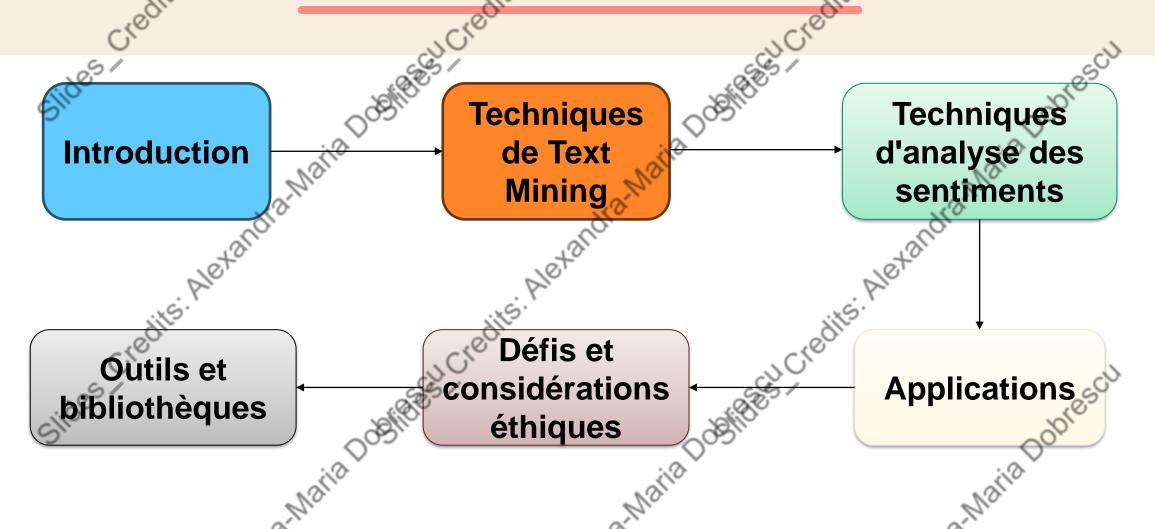
Alexandra-Maria DOBRESCU

| Cours 11 |

sujets andra natia Dobinas III. Alexandro avancés ou émérgents de la fille de la fi

Naira Dobling Bell Credits. Alexandra

AVD | Cours 11



AVD | Cours 11 | AMD

LE TEXT MINING, ÉGALEMENT CONNU SOUS LE NOM D'ANALYSE DE TEXTE OU D'EXTRACTION D'INFORMATIONS, EST LE PROCESSUS QUI CONSISTE À DÉRIVER DES MODÈLES SIGNIFICATIFS, DES IDÉES ET DES CONNAISSANCES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

Idée 1: Contrairement aux données structurées que l'on trouve dans les bases de données, les données non structurées se présentent généralement sous la forme de courriels, de documents, de messages sur les médias sociaux, d'articles et d'autres sources de texte.

Idée 2: Le text mining fait appel à diverses techniques et méthodes pour transformer les textes non structurés en informations structurées, ce qui facilite l'analyse et l'extraction d'informations précieuses. Les principaux objectifs du text mining sont les suivants:

> Recueil d'informations | Extraction de texte | Reconnaissance des formes Analyse des sentiments | Découverte de connaissances

- Recueil d'informations: Localisation et récupération d'informations pertinentes à partir d'un large corpus de textes (Information Retrieval).
- Extraction de texte: Identification et extraction d'informations spécifiques, telles que des entités nommées (par exemple, des noms, des lieux, des organisations) et des relations (Text Extraction).
- Reconnaissance des formes: Découverte de modèles, de tendances et de relations dans les données textuelles (Pattern Recognition).
- Analyse des sentiments: Détermination du sentiment ou du ton émotionnel exprimé dans le texte, qu'il soit positif, négatif ou neutre (Sentiment Analysis).
- Découverte de connaissances: Découverte de connaissances cachées et compréhension approfondie du contenu des données textuelles (Knowledge Discovery).

#### nce et Applications:

- Le text mining s'appuie sur une combinaison de techniques de traitement du langage naturel (NLP), d'apprentissage automatique et de statistiques pour traiter et analyser efficacement de grands volumes de texte.
- Il joue un rôle crucial dans divers domaines, notamment la business intelligence, les soins de santé, l'analyse des médias sociaux, etc., en permettant aux organisations de prendre des décisions éclairées sur la base des informations textuelles.

Le traitement de gros volumes de données textuelles: Un aspect essentiel de l'exploration de texte et implique l'utilisation de techniques et d'outils capables de traiter et d'analyser efficacement de vastes quantités de textes non structurés.

Introduction

<u>Le traitement de gros volumes de données textuelles</u>

Points clés	Les détails
Évolutivité  Credits: Alexandra. M	Les techniques de text mining doivent être évolutives pour faire face aux volumes toujours croissants de données textuelles générées quotidiennement. Comme les organisations accumulent de vastes référentiels de documents, de courriels, de messages sur les médias sociaux et d'autres contenus textuels, la capacité à faire évoluer les processus d'exploration de texte devient cruciale.
Traitement parallèle	Pour accélérer l'analyse de grands ensembles de données, des techniques de traitement parallèle sont souvent utilisées. La répartition de la charge de travail sur plusieurs processeurs ou nœuds informatiques permet d'accélérer l'extraction, la transformation et l'analyse des textes.

AVD | Cours 11 | AMD

"Also	941.0
Points clés	Les détails ple tails
Informatique distribuée	L'utilisation de cadres informatiques distribués, tels qu'Apache Hadoop ou Apache Spark, peut améliorer la vitesse de traitement et l'efficacité des tâches d'exploration de texte. Ces cadres permettent le traitement de grands ensembles de données sur des grappes de machines.
Cloud Computing (informatique en nuage)	Les plateformes d'informatique en nuage fournissent des ressources évolutives et à la demande, ce qui les rend adaptées au traitement de grands volumes de données textuelles. Les services en nuage permettent aux organisations de déployer des applications de text mining sans avoir à investir lourdement dans l'infrastructure.
Indexation et récupération (retrieval)	Des mécanismes efficaces d'indexation et d'extraction sont essentiels pour accéder rapidement aux informations pertinentes contenues dans les grands ensembles de données textuelles. Des techniques telles que la création d'index inversés ou l'utilisation de moteurs de recherche peuvent accélérer considérablement le processus d'extraction.

oglio.	office of the state of the stat
Points clés	Les détails pretains
Traitement par lots et streaming	En fonction de la nature des données textuelles, les organisations peuvent utiliser des techniques de traitement par lots ou de diffusion en continu. Le traitement par lots convient à l'analyse de grands ensembles de données historiques, tandis que le traitement en continu est utilisé pour l'analyse en temps réel de flux de textes entrants en continu.
Prétraitement des données	Avant d'être analysées, les données textuelles sont souvent soumises à des étapes de prétraitement pour les nettoyer, les normaliser et les transformer dans un format approprié. Ce prétraitement est essentiel pour traiter le bruit, les informations non pertinentes ou les incohérences dans les grands ensembles de données.
Algorithmes optimisés	Il est important de choisir des algorithmes optimisés pour le traitement de textes à grande échelle. Des techniques telles que les algorithmes distribués d'apprentissage automatique ou les algorithmes conçus pour le traitement parallèle peuvent améliorer de manière significative l'efficacité des tâches d'exploration de texte.

Introduction

L'extraction d'idées et de tendances dans le contexte du text mining fait référence au processus de découverte d'informations précieuses et significatives à partir de grands volumes de données textuelles non structurées. Il s'agit d'utiliser diverses techniques et algorithmes pour identifier les thèmes récurrents, les relations et les tendances dans le texte.

Il peut s'agir de découvrir les mots ou les phrases les plus fréquents, de reconnaître des modèles de sentiment dans différents documents ou d'extraire des sujets et des entités clés..

Introduction

L'extraction de modèles vise à révéler des structures, des associations ou des séquences dans le texte, ce qui permet de mieux comprendre les informations sous-jacentes.

En extrayant des informations et des modèles, les organisations peuvent:

prendre des décisions éclairées. acquérir un avantage concurrentiel

tirer des connaissances exploitables du contenu textuel étendu et souvent complexe qu'elles rencontrent:

- dans les documents,
- les médias sociaux,
- les commentaires des clients
  - d'autres sources.

LES TECHNIQUES D'EXPLORATION DE TEXTE IMPLIQUENT UNE SÉRIE DE PROCESSUS ET DE MÉTHODES VISANT À EXTRAIRE DES INFORMATIONS PRÉCIEUSES ET DES MODÈLES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

La tokenisation: Le processus de décomposition d'un texte en mots ou phrases individuels, appelés « tokens ».

Cette technique facilite l'analyse ultérieure en convertissant le texte en un format plus facile à gérer et plus structuré.

```
# Exemple de texte
text = "La tokenisation est une étape importante dans le traitement du langage
nature
# Tokeniser le texte
tokens = word_tokenize(tox
                                                     'importante',
       'tokenisation\\, 'est', 'une',
                                          'étape',
'traitement', 'du', langage', 'naturel',
```

LES TECHNIQUES D'EXPLORATION DE TEXTE IMPLIQUENT UNE SÉRIE DE PROCESSUS ET DE MÉTHODES VISANT À EXTRAIRE DES INFORMATIONS PRÉCIEUSES ET DES MODÈLES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

2. Suppression des mots vides: Les mots vides sont des mots courants (par exemple, « le », « et », « est ») qui n'ont souvent qu'une faible signification sémantique.

La suppression des mots vides permet de se concentrer sur les mots plus significatifs, de réduire le bruit et d'améliorer l'efficacité de l'analyse de texte.

```
# Supprimer les mots vide
stop_words = set(stopwords.words('french'))
filtered_tokens = [word for word in tokens if word lower() not in stop_word
                        , 'importante', 'traitement', 'langage', 'naturel', '.']
['tokenisation', 'étape'
```

LES TECHNIQUES D'EXPLORATION DE TEXTE IMPLIQUENT UNE SÉRIE DE PROCESSUS ET DE MÉTHODES VISANT À EXTRAIRE DES INFORMATIONS PRÉCIEUSES ET DES MODÈLES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

3. Le stemmage et la lemmatisation: Le stemming consiste à réduire les mots à leur forme de base ou racine, tandis que la lemmatisation vise à transformer les mots en leur forme dictionnaire ou canonique.

Ces deux techniques permettent de normaliser les mots et de réduire les variations pour une analyse plus précise.

```
# Stemming (using SnowballStemmer for French)
stemmer = SnowballStemmer(Grench')
stemmed_tokens = [stemmeo.stem(word) for word io filtered_tokens]
['tokenis', 'étap', 'import', 'trait', 'langag', 'naturel', '.']
                                AVD | Cours 11 | AMD
```

LES TECHNIQUES D'EXPLORATION DE TEXTE IMPLIQUENT UNE SÉRIE DE PROCESSUS ET DE MÉTHODES VISANT À EXTRAIRE DES INFORMATIONS PRÉCIEUSES ET DES MODÈLES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

3. Le stemmage et la lemmatisation: Le stemming consiste à réduire les mots à leur forme de base ou racine, tandis que la lemmatisation vise à transformer les mots en leur forme dictionnaire ou canonique.

Ces deux techniques permettent de normaliser les mots et de réduire les variations pour une analyse plus précise.

```
# Lemmatization (using WordNetLemmatizer for English, use a French lemmatizer for
better results)
```

```
lemmatizer = WordNetLemmatizer()
```

```
lemmatized_tokens = [lemmatizer.lemmatize(word) of or word in filtered_tokens]
```

```
['tokenisation', 'étape', 'importante', 'traitement', 'langage', 'naturel', '.']
                                 AVD | Cours 11 | AMD
```

LES TECHNIQUES D'EXPLORATION DE TEXTE IMPLIQUENT UNE SÉRIE DE PROCESSUS ET DE MÉTHODES VISANT À EXTRAIRE DES INFORMATIONS PRÉCIEUSES ET DES MODÈLES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

Reconnaissance des entités nommées (NER): consiste à identifier et à classer des entités nommées dans un texte, telles que des noms, des lieux, des organisations, des dates et d'autres entités spécifiques.

Cette technique est essentielle pour extraire des informations structurées d'un texte non structuré.

```
# Perform Named Entity Recognition (NER)
```

tokenisation/NN, étape/NN, importante/JJ, traitement/NN, langage/NN, naturel/NN

LES TECHNIQUES D'EXPLORATION DE TEXTE IMPLIQUENT UNE SÉRIE DE PROCESSUS ET DE MÉTHODES VISANT À EXTRAIRE DES INFORMATIONS PRÉCIEUSES ET DES MODÈLES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

5. L'étiquetage des parties du discours (POS): attribue des catégories grammaticales (par exemple, nom, verbe, adjectif) aux mots d'une phrase.

Ces informations permettent de comprendre la structure syntaxique du texte, ce qui facilite une analyse plus poussée.

```
# Perform Named Entity Recognition (NER)
ner_tag = ne_chunk(nltk.pos_tag(filtered_tokens)
```

tokenisation/NN, étape/NN, importante/JJ, traitement/NN, langage/NN, naturel/NN

LES TECHNIQUES D'EXPLORATION DE TEXTE IMPLIQUENT UNE SÉRIE DE PROCESSUS ET DE MÉTHODES VISANT À EXTRAIRE DES INFORMATIONS PRÉCIEUSES ET DES MODÈLES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

Vectorisation de texte: consiste à convertir des données textuelles en représentations numériques que les algorithmes d'apprentissage automatique peuvent traiter. Des techniques telles que Term Frequency-Inverse Document Frequency (TF-IDF) et les enchâssements de mots (par exemple, Word2Vec, GloVe) sont couramment utilisées à cette fin.

#### The cat sat on the mat

ides The:[0100000]

cat: [0010000]

sat: [0001000]

on: [0000100]

the: [0000010]

[3] mat: [0000001]

LES TECHNIQUES D'EXPLORATION DE TEXTE IMPLIQUENT UNE SÉRIE DE PROCESSUS ET DE MÉTHODES VISANT À EXTRAIRE DES INFORMATIONS PRÉCIEUSES ET DES MODÈLES À PARTIR DE DONNÉES TEXTUELLES NON STRUCTURÉES.

Vectorisation de texte: consiste à convertir des données textuelles en représentations numériques que les algorithmes d'apprentissage automatique peuvent traiter. Des techniques telles que Term Frequency-Inverse Document Frequency (TF-IDF) et les enchâssements de mots (par exemple, Word2Vec, GloVe) sont couramment utilisées à cette fin.

#### The cat sat on the mat

ides The:[0100000]

cat: [0010000]

sat: [0001000]

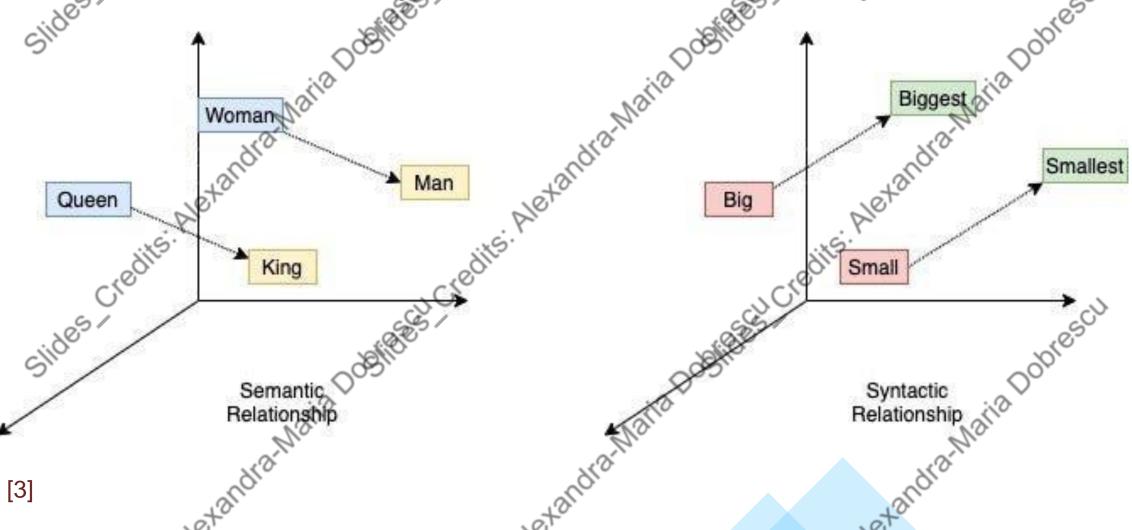
on: [0000100]

the: [0000010]

[3] mat: [0000001]

La distance euclidienne entre Femme et Reine serait la même que celle entre Homme et Roi. Nous pouvons donc représenter algébriquement la relation sémantique comme suit:

Queen-Woman = King-Man OU Queen-Woman+Man = King



# Analyse de Sentiments Techniques d'analyse

des sentiments

LES TECHNIQUES D'ANALYSE DES SENTIMENTS CONSISTENT À ÉVALUER ET À DÉTERMINER LA TONALITÉ ÉMOTIONNELLE EXPRIMÉE DANS UN TEXTE, EN LE CLASSANT GÉNÉRALEMENT COMME POSITIF, NÉGATIF OU NEUTRE.

#### Méthodes basées sur des règles:

- Analyse de sentiments basée sur un lexique: Utilise des lexiques ou des dictionnaires de sentiments contenant des mots associés à des sentiments positifs ou négatifs. Elle attribue des notes aux mots et calcule une note globale de sentiment pour le texte en fonction de la présence et de l'intensité de ces mots.
- · Correspondance de motifs (Pattern Matching): implique la définition de règles ou de motifs qui capturent des structures linguistiques ou des expressions spécifiques indiquant un sentiment. Cette méthode peut s'avérer efficace pour identifier le sentiment dans des textes informels, tels que les médias sociaux.

# Analyse de Sentiments Techniques d'analyse

des sentiments

LES TECHNIQUES D'ANALYSE DES SENTIMENTS CONSISTENT À ÉVALUER ET À DÉTERMINER LA TONALITÉ ÉMOTIONNELLE EXPRIMÉE DANS UN TEXTE, EN LE CLASSANT GÉNÉRALEMENT COMME POSITIF, NÉGATIF OU NEUTRE.

#### Approches de l'apprentissage automatique:

- Apprentissage supervisé: Entraîne un modèle sur un ensemble de données étiquetées contenant des échantillons de texte avec les étiquettes de sentiment correspondantes (positif, négatif, neutre). Les algorithmes courants comprennent Naive Bayes, les machines à vecteurs de support et les arbres de décision.
- · Apprentissage non supervisé: Il applique des techniques de regroupement ou de modélisation thématique pour regrouper des textes similaires, ce qui permet de déduire le sentiment sur la base du sentiment dominant au sein de chaque groupe.

# Analyse de Sentiments Techniques d'analyse

des sentiments

#### Apprentissage profond pour l'analyse des sentiments: 3.

- Réseaux neuronaux récurrents (RNN): Adaptés aux données séquentielles, les RNN peuvent capturer des informations contextuelles et des dépendances dans le texte. Les réseaux à mémoire à long terme (LSTM) et les unités récurrentes gérées (GRU) sont des variantes populaires.
- Réseaux neuronaux convolutifs (CNN): Appliqués au texte par le biais de couches convolutives afin d'identifier des modèles locaux dans les données. Ils sont efficaces pour l'analyse des sentiments lorsqu'ils sont combinés à des couches de mise en commun.
- Transformateurs (par exemple, BERT): modèles bidirectionnels qui prennent en compte l'ensemble du contexte d'un mot dans une phrase. BERT (Bidirectional Encoder Representations from Transformers) a fait ses preuves dans diverses tâches de traitement du langage naturel, y compris l'analyse des sentiments.

# Analyse de Sentiments Techniques d'anal

des sentiments

- Analyse de sentiment basée sur les aspects: Elle va au-delà du sentiment général et analyse le sentiment à l'égard d'aspects ou de caractéristiques spécifiques mentionnés dans le texte. Utile pour les évaluations de produits ou les commentaires des clients.
- Méthodes d'ensemble (Combinaison de modèles): Intègre les prédictions de plusieurs 5. modèles d'analyse du sentiment afin d'améliorer la précision et la robustesse. Les méthodes d'ensemble peuvent inclure un mélange de modèles basés sur des règles, d'apprentissage automatique et d'apprentissage profond.
- Personnalisation spécifique au domaine (Dictionnaires personnalisés): dictionnaires de sentiments spécifiques à un domaine, adaptés au vocabulaire et au contexte d'une industrie ou d'un domaine particulier.

# Analyse de Sentiments Techniques d'anal

des sentiments

- Approches hybrides (basée sur des règles et apprentissage automatique): combine les avantages des méthodes basées sur des règles pour l'interprétabilité et des méthodes d'apprentissage automatique pour l'apprentissage de modèles complexes.
- Apprentissage par transfert: Utilise des modèles préformés sur de grands ensembles de données pour une compréhension générale du sentiment, puis les affine sur des données spécifiques à un domaine pour améliorer les performances.

Le choix de la technique d'analyse des sentiments appropriée dépend de facteurs tels que le volume de données, le contexte de l'application et le niveau de granularité souhaité dans l'analyse des sentiments. Différentes techniques peuvent être plus adaptées à différents scénarios et domaines.

#### bibliothèques

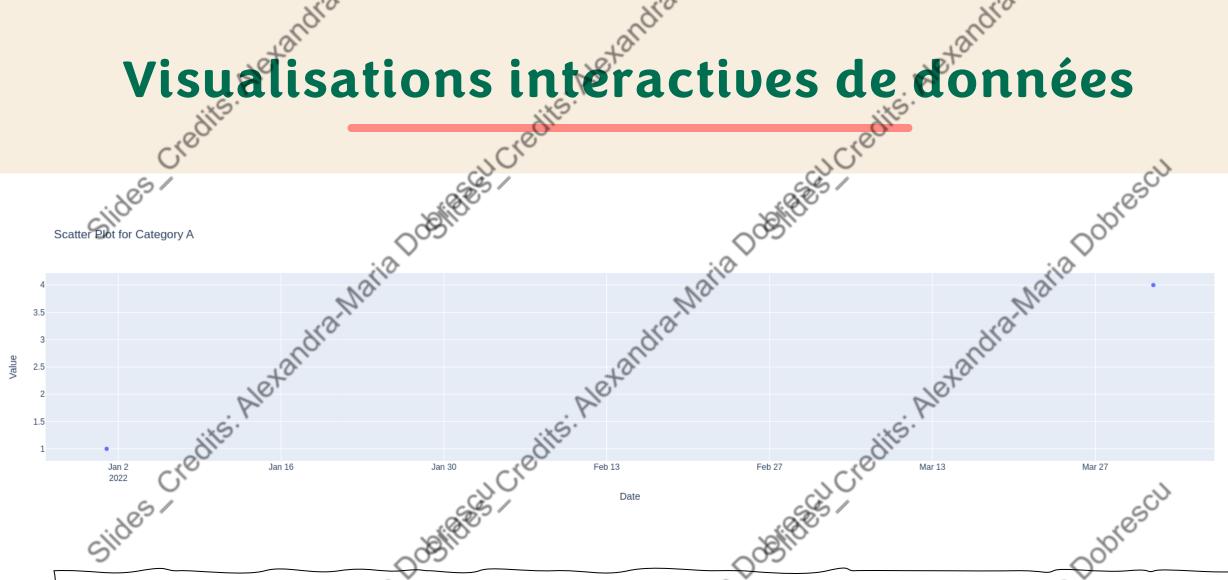
- NLTK (Natural Language Toolkit): uissante bibliothèque Python pour travailler avec des données de langage humain. Elle fournit des interfaces faciles à utiliser pour des tâches telles que la tokenisation, le stemming, la lemmatisation, l'étiquetage POS, et plus encore.
- SpaCy: bibliothèque de traitement du langage naturel open-source de qualité industrielle. Conçue pour être efficace, elle fournit des modèles pré-entraînés pour différentes langues et tâches telles que la reconnaissance d'entités nommées, l'étiquetage de la partie du discours et l'analyse des dépendances
- <u>TextBlob</u>: bibliothèque simplifiée de traitement du langage naturel pour Python. Elle fournit une API simple pour les tâches courantes de traitement du langage naturel telles que l'étiquetage de la partie du discours, l'extraction de phrases nominales, l'analyse des sentiments, la classification, la traduction, et plus encore.

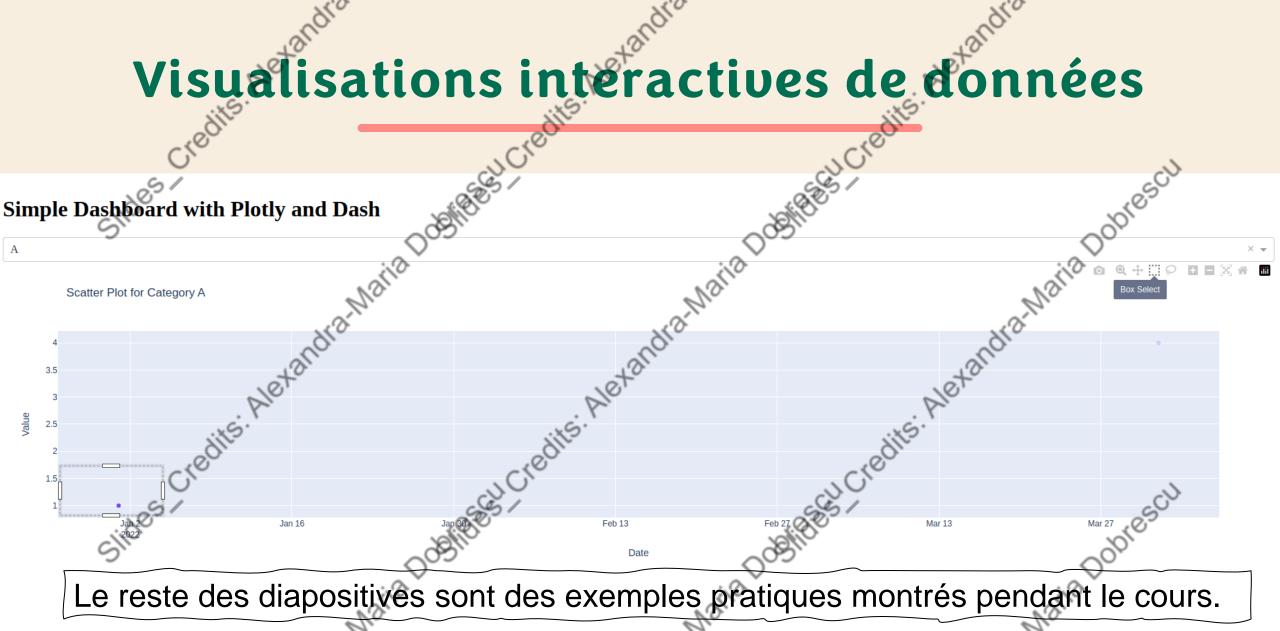
#### bibliothèques

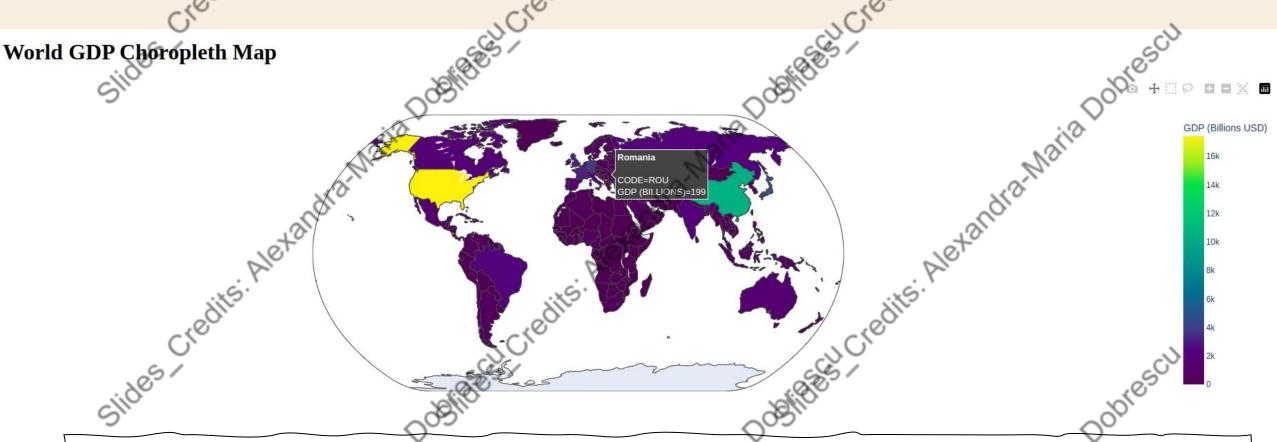
- 4. Scikit-learn: bibliothèque d'apprentissage automatique en Python. Bien qu'elle ne soit pas spécifiquement destinée à l'exploration de texte, elle comprend des modules pour la vectorisation de texte (par exemple, TF-IDF), l'extraction de caractéristiques et les algorithmes de classification qui sont couramment utilisés dans l'analyse de texte.
- 5. Gensim: bibliothèque Python pour la modélisation de sujets et l'analyse de similarité de documents. Elle fournit des implémentations d'algorithmes tels que Latent Semantic Analysis (LSA) et Latent Dirichlet Allocation (LDA) pour l'extraction de sujets à partir de corpus de textes.
- 6. Modèles Word2Vec: Word2Vec est une famille de modèles d'intégration de mots qui représentent les mots dans un espace vectoriel, capturant les relations sémantiques. Les modèles Word2Vec pré-entraînés (par exemple, Google's Word2Vec) sont souvent utilisés pour des tâches telles que la similarité des mots et le regroupement de documents.

CRÉER UNE PRÉSENTATION AVEC DASH ET PLOTLY, C'EST CONCEVOIR LA STRUCTURE VISUELLE ET LES COMPOSANTS D'UN TABLEAU DE BORD EN LIGNE À L'AIDE DE DASH, TOUT EN UTILISANT PLOTLY POUR CRÉER DES GRAPHIQUES OU DES DIAGRAMMES INTERACTIFS ET VISUELLEMENT ATTRAYANTS DANS CE TABLEAU DE BORD.

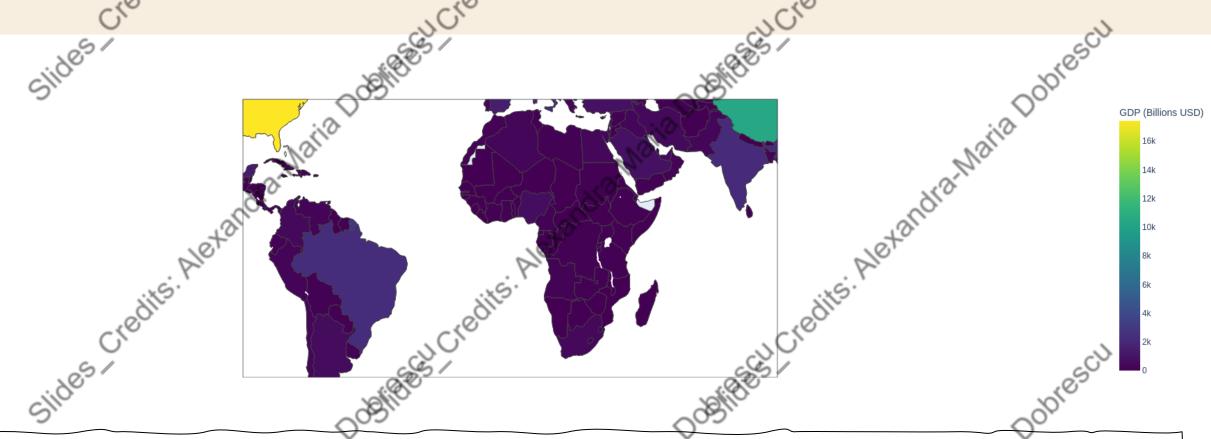
- 1. <u>Dash</u>: framework Python permettant de créer des applications web analytiques. Il vous permet de créer des tableaux de bord interactifs basés sur le web à l'aide de code Python. Dash fournit une syntaxe simple pour définir la présentation de votre application, gérer les interactions avec l'utilisateur et mettre à jour le contenu de manière dynamique.
- 2. <u>Plotly</u>: bibliothèque graphique Python qui vous permet de créer une variété de visualisations interactives, y compris des tracés, des graphiques et des tableaux de bord. Elle fournit des graphiques interactifs de haute qualité pour l'analyse des données.





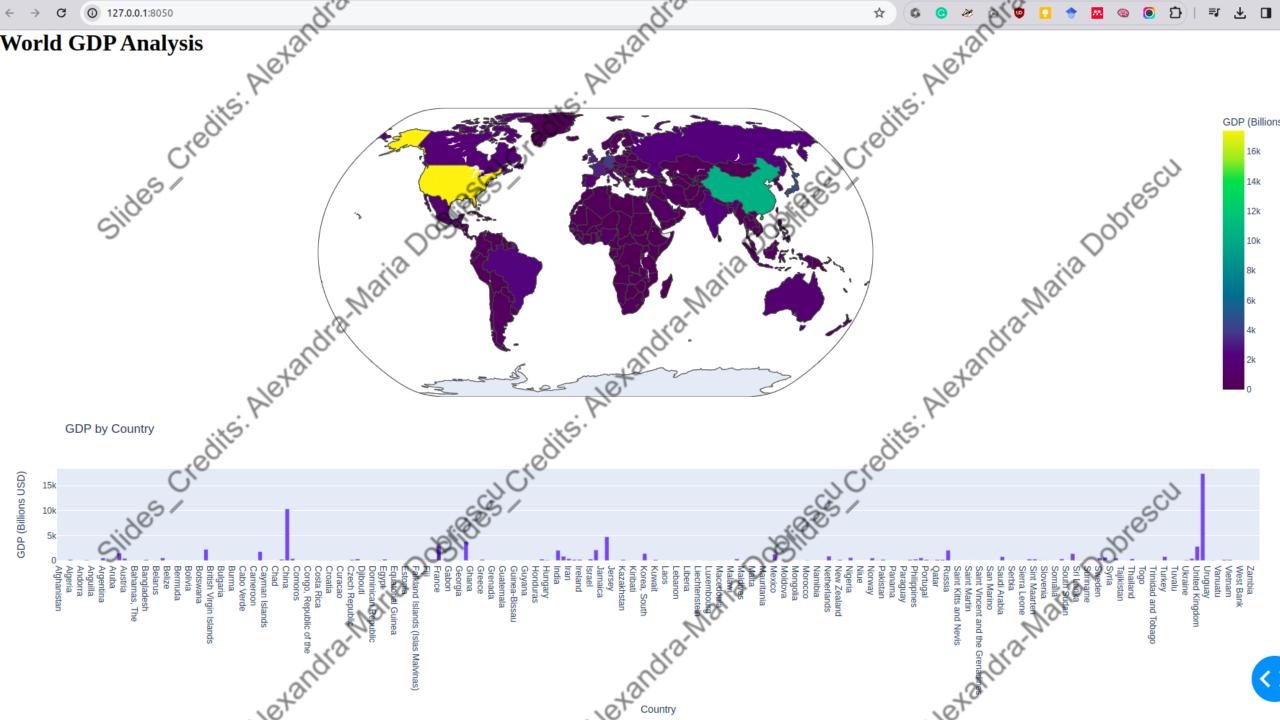


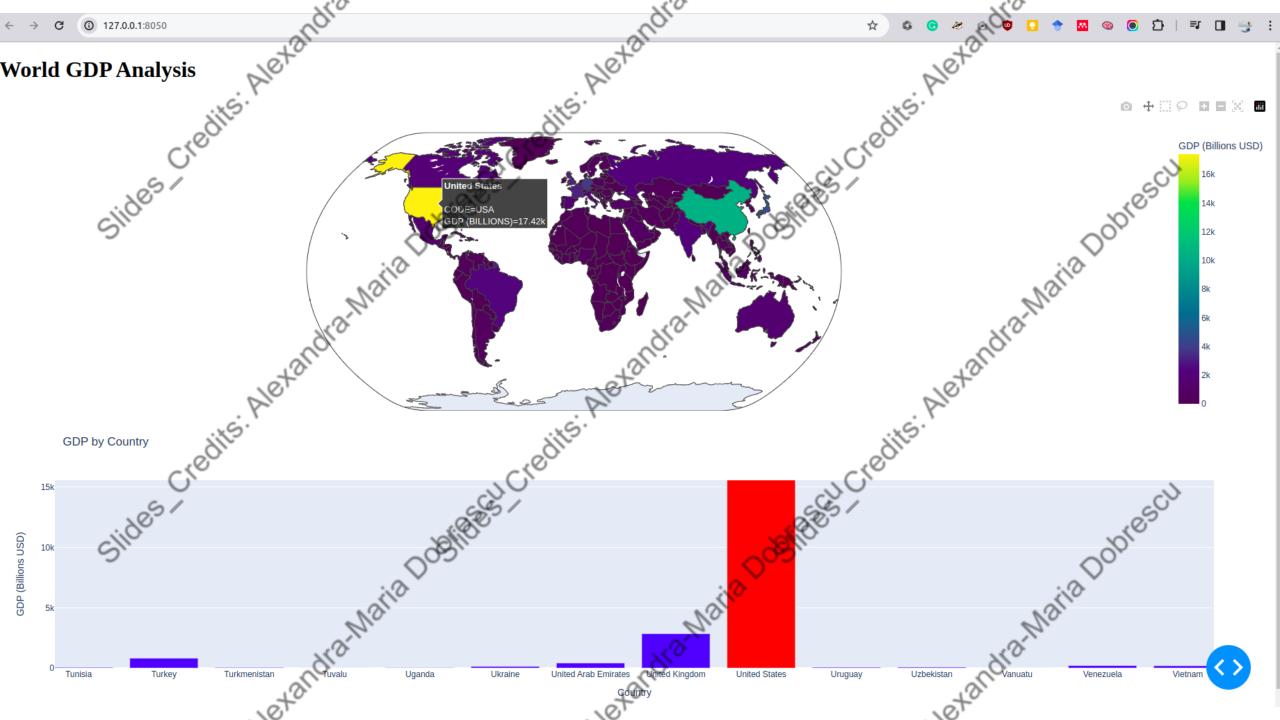




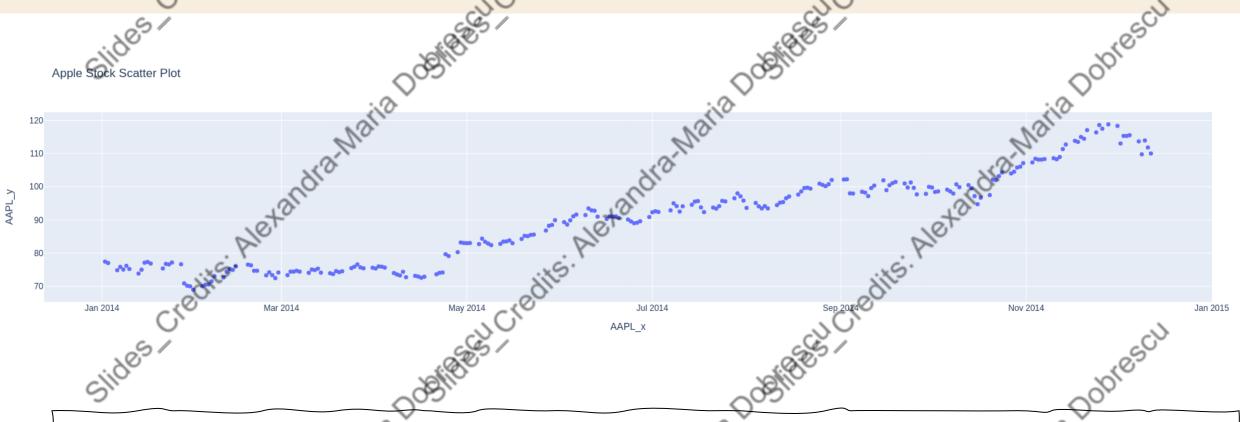


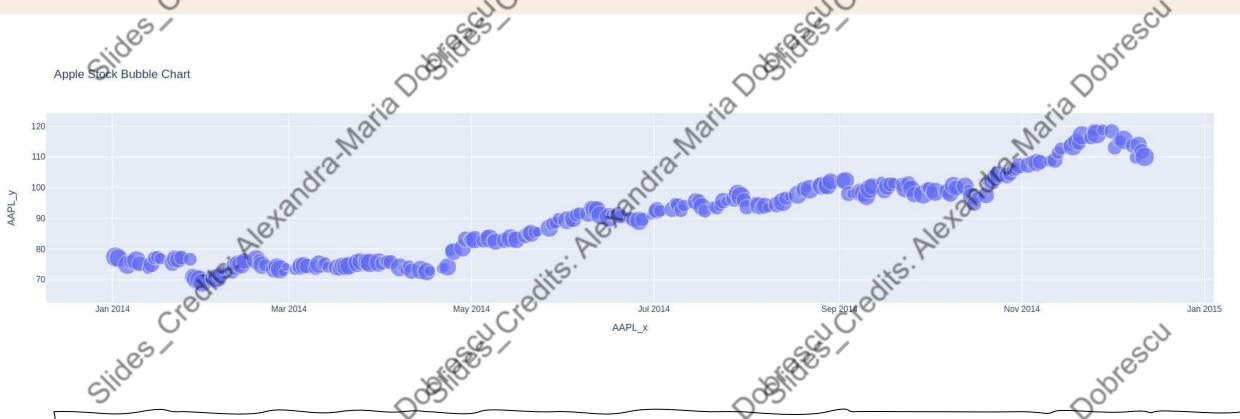


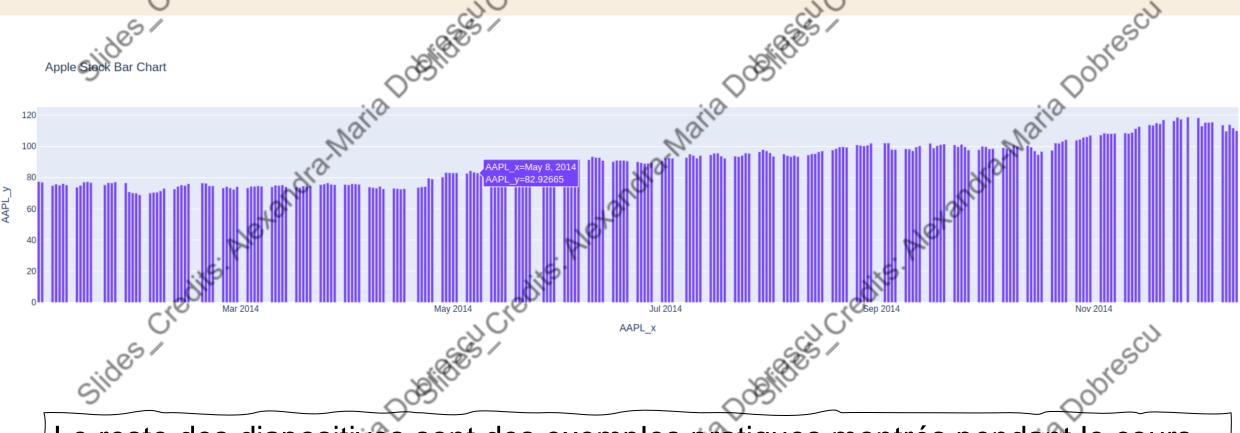




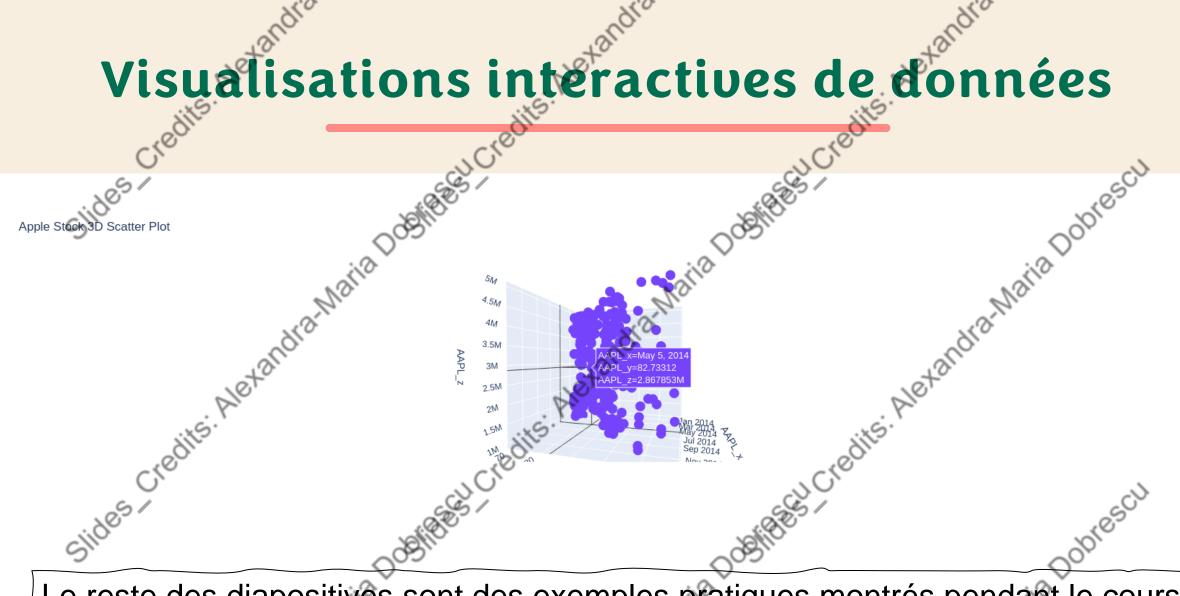












# Bibliographie

- [1] Subramaniam, A. (2020). What Is Big Data Analytics Big Data Analytics Tools and Trends edureka.

  [2] Bishop, E. M., & Nasrabadi, N. M. (2006). Pateri recognition and machine learning (Vol. 4). No. 4, p. 738). New York: springer.

  [3] https://becominghuman.ai/mathematical-influduction-to-glove-word-embedding-60/24/54e54c

  [4] https://cloud.google.com/natural-language
  [6] https://plotly.com/blog/python-tools-for-data-science/
  [7] https://dash.gallery/dash.pale/v/dash.pale/

  [8] https://dash.gallery/dash.pale/

  [9] https://dash.gallery/dash.pale/

  [1] https://dash.gallery/dash-sne/

  [1] https://dash.gallery/dash-sne/

  [1] https://dash.gallery/dash-sne/

  [2] https://dash.gallery/dash-sne/

redits. Alexandra